

“萤目守望” 功能与性能测试报告

文档状态：工程基线已具备；真实实验结果待 P03 盲测和 12 小时运行后写入。

1 测试范围

测试覆盖契约与状态机、后端 API、算法适配、前端交互、萤石平台能力、智能体解释、异常降级、三参与者算法实验、12 小时稳定性和 Windows 发布包。

2 工程自动化测试

2026 年 8 月 21 日对工作区快照（基准提交 [f18c723cdd69](#) 及本交付改动）完成回归：后端 pytest 222/222、前端 Vitest 96/96 通过，Vite 完成 2317 个模块转换。补丁升级 3 个间接依赖后，[npm audit](#) 报告 0 个已知漏洞。

Windows 目录包由 PyInstaller 6.15.0 构建；隔离数据库全栈冒烟到达 [RESOLVED](#)，Vue 检查通过，退出后残留进程为 0。ZIP SHA-256 为

[0b9d733c8caa6de4598272b39d17cd405f4bc76d45c01405aef1105ba24e9a12](#)；1331 条包内清单均匹配，敏感扫描无发现。该记录不替代另一台干净 Windows 电脑的验收。

3 已有实机与闭环证据

- 真实萤石抓拍：独立 10 次成功，报告不含凭证或临时 URL。
- 授权录像闭环：快速起身、躯干摇摆、Mock 干预、姿态恢复、观察和 [RESOLVED](#) 已通过一次完整验收。
- 智能体：Qwen 成功路径和模板降级均有脱敏记录；模型不修改风险状态。
- 异常测试：Token 失效、设备离线、抓拍超时、Qwen 超时、非法 JSON 和敏感信息扫描已有记录。

真实抓拍不能证明视频时序算法闭环；授权录像必须标记 [RECORDED_REPLAY/simulated=true](#)；Mock 语音不能描述为萤石服务端语音。

4 三参与者实验结果

PENDING_REAL_DATA: 由 experiment-results.json 生成。

最终表必须列出 P01、P02、P03 的样本量和混淆矩阵，并以 P03 配置 A 的 24 段作为主测试结果。至少报告 TP、TN、FP、FN、Precision 及 95% Wilson 区间、Recall 及 95% Wilson 区间、F1、高风险窗口召回率和延迟。

5 消融实验

PENDING_REAL_DATA: A 完整系统、B 无个人基线、C 仅短时、D 无质量/上下文门控均须使用同一 P03 测试集和冻结规则。

不得针对消融配置重新调参或删除失败样本。

6 12 小时稳定性

PENDING_REAL_DATA: 三名参与者各 4 小时，Mock 时间不得计入。

报告总时长、风险事件、人工复核误报、每小时误报率、系统异常、重启和未处理异常。三次运行分别报告并汇总。

7 Windows 发布验收

当前本机构建和全栈冒烟已通过。最终验收环境必须未安装项目 Python 或 Node 依赖，并继续检查解压、3 分钟内启动、九个页面、来源标识、关闭后的残留进程、敏感扫描和 SHA-256 清单。另一台 Windows 电脑尚未验收，因此不得把本节标记为最终通过。

8 结论规则

若 F1、召回、P95 延迟或误报率未达到内部目标，应如实报告实际值和原因，不继续修改 P03 标签或筛选成功样本。只有全部真实数据完成且文档中不存在 `PENDING_` 标记时，测试报告才能改为最终版。